

Test Kołmogorowa–Smirnowa

Adam Przemysław Chojewski

Dla próbki $A = (a_1, a_2, \dots, a_n)$ liczb rzeczywistych ($a_i \in \mathbb{R}$) definiujemy empiryczną dystrybuantę (ang. ECDF) jako funkcję:


$$\mathbb{R} \ni x \mapsto F_A(x) = \frac{|\{a_i \leq x\}|}{n}.$$

Jest to funkcja schodkowa, niemalejąca, przyjmująca wartości od 0 do 1, prawostronnie ciągła.

Dla dwóch próbek A i B statystyka testowa Kołmogorowa–Smirnowa zdefiniowana jest jako:

$$D = \sup_{x \in \mathbb{R}} |F_A(x) - F_B(x)|,$$

czyli największa (co do modułu) odległość między wartościami empirycznych dystrybuant.



Rysunek 1: Empiryczne dystrybuanty dla próbek $A = (1, 2, 4)$ oraz $B = (1, 3, 3, 5)$. Największa odległość między dystrybuantami wynosi $D = \frac{5}{12}$ i jest osiągana dla każdego $x \in [2, 3)$.

Etap 1 (0.5 pkt.)

Dane są dwie uporządkowane niemalejąco próbki:

- `double[] sample1`
- `double[] sample2`

Należy obliczyć wartość statystyki D .

Wymagana złożoność obliczeniowa: $O(n_1 + n_2)$, gdzie n_1 i n_2 są długościami odpowiednich próbek.

Uwagi:

- Próbki mogą mieć różne długości.
- Wartości w próbkach mogą się powtarzać.
- Może być zarówno `sample1[i] == sample1[j]`, jak i `sample1[i] == sample2[j]`.

Etap 2 (0.5 pkt.)

Dane jest K próbek, każda z nich uporządkowana niemalejąco:

$$A^{(1)}, A^{(2)}, \dots, A^{(K)}.$$

Niech n_i oznacza długość i -tej próbki oraz

$$n = n_1 + n_2 + \dots + n_K.$$

Niech $F_i(x)$ oznacza empiryczną dystrybuantę i -tej próbki.

Zdefiniujmy statystykę D jako największą odległość pomiędzy wartościami dowolnych dwóch empirycznych dystrybuant w tym samym punkcie x :


$$D = \sup_{x \in \mathbb{R}} \left\{ \max_{1 \leq i, j \leq K} |F_i(x) - F_j(x)| \right\} = \sup_{x \in \mathbb{R}} \left\{ \left(\max_{1 \leq i \leq K} F_i(x) \right) - \left(\min_{1 \leq j \leq K} F_j(x) \right) \right\}.$$

Należy obliczyć wartość D .

Wymagana złożoność obliczeniowa: $O(nK)$.

Etap 3 (1.5 pkt.)

Rozwiąż problem z Etapu 2 z lepszą złożonością $O(n \log K)$.



Rysunek 2: Empiryczne dystrybuanty dla trzech próbek $A = (1, 2, 4)$, $B = (1, 3, 3, 5)$ oraz $C = (4, 5, 5)$. Największa odległość między wartościami dowolnych dwóch dystrybuant wynosi $D = \frac{3}{4}$ i jest osiągana dla każdego $x \in [3, 4)$.

Dane wejściowe i wyjściowe

Wejście:

- W etapie 1: dwie tablice typu `double[]`.
- W etapie 2 i 3: tablica tablic typu `double[][]`.

Wyjście:

- Wartość statystyki jako liczba typu `double`.

Uwagi

- Wszystkie próbki są niepuste.
- W etapie 2 i 3, $K \geq 2$.
- W próbkach nie występują wartości NaN ani nieskończoności.
- Wartości różniące się o mniej niż 10^{-6} można uznać za równe.